

基于 LSTM-GA 混合模型的患者预约排队策略优化

魏若楠¹, 江驹¹, 徐海燕²

(1. 南京航空航天大学 自动化学院, 江苏 南京 211106; 2. 南京航空航天大学 经济与管理学院, 江苏 南京 211106)

摘要:在医疗运作管理领域,合理的资源分配能够帮助更多的患者尽早就医,降低患者病情恶化和死亡的风险。本文设计了预约排队策略对患者占有资源的顺序进行分配,建立了基于长短时记忆(Long Short Term-Memory, LSTM)神经网络和遗传算法(Genetic Algorithm, GA)的混合模型以优化排队策略。首先利用大数据和深度学习分析患者到达和医院服务情况,建立 LSTM 神经网络学习数据特征并预测未来数据,相比于排队论常用的随机分布方法取得了更好的效果。其次设计了基于排队系统仿真的排队策略优化算法,利用改进 GA 得到最优排队策略。实证研究表明,文本的方法可以明显降低患者的等待时间,最高可达 59%。最后对排队策略进行敏感性分析,结果表明排队策略有效作用于仿真的各个时段。

关键词:系统优化;运作管理;排队策略;遗传算法;长短时记忆神经网络

中图分类号:TP391.9 **文章标识码:**A **文章编号:**1007-3221(2022)03-0017-07 **doi:**10.12005/orms.2022.0072

Optimization of Patient Reservation Queuing Policy Based on LSTM-GA Hybrid Model

WEI Ruo-nan¹, JIANG Ju¹, XU Hai-yan²

(1. School of Automation, Nanjing University of Aeronautics and Astronautics, Nanjing 211106, China; 2. School of Economics and Management, Nanjing University of Aeronautics and Astronautics, Nanjing 211106, China)

Abstract: In the field of medical operation and management, a reasonable allocation of resources is conducive to more patients to seek medical treatment as soon as possible and reduce the risk of patients' disease deterioration and death. Reservation queuing policy is designed to allocate the order of patients' occupying resources. A hybrid model based on long Short Term Memory (LSTM) neural network and genetic algorithm (GA) is established to optimize the queuing policy. First, big data and deep learning are used to analyze patient arrival and hospital service, and LSTM neural network is established to learn data features and predict future data. Compared with the random distribution method commonly used in queuing theory, it has achieved better results. Secondly, a queuing policy optimization algorithm based on queuing system simulation is designed to obtain the optimal queuing policy by using improved GA. The empirical studies show that the method of text can significantly reduce the patient's waiting time, which lowers the target function by 59%. Finally, the sensitivity of the queuing policy is analyzed, and the results show that the queuing policy is effective in each period of the simulation.

Key words: system optimization; operation management; queuing strategy; genetic algorithm; long short-term memory neural network

0 引言

在国内外部分地区,患者通过预约进行身体检查或治疗。部分发达国家的预约就诊已经普及多年,然而排队现象依然常见,在公立医院尤为严重。

虽然我国预约就诊尚未普及,但预约住院、手术、检查等已有所实施。部分预约项目排队现象十分严重,排队时间少则半个月,多则一年^[1]。对病情很轻的患者而言,他们有能力接受一定程度的等待;对病情严重的患者而言,等待可能会加速病情恶化甚至死亡^[2]。国外许多医院摒除先来先服务排队

收稿日期:2020-11-02

基金项目:国家自然科学基金资助项目(71971115,61673209,71471087);南京航空航天大学基本业务费(NG2020004);南京航空航天大学基本业务费培育基金(NG2020004)

作者简介:魏若楠(1996-),女,重庆人,硕士研究生,研究方向:智能优化;江驹(1963-),男,通讯作者,江苏扬州人,教授,博士,研究方向:智能控制与优化;徐海燕(1963-),女,江苏扬州人,教授,博士,研究方向:冲突决策分析与优化。

规则,目前我国部分医院也开始效仿此措施,2019年5月起,北京20家设有急诊的市属三甲医院启动了急诊预检的分级就诊^[3]。在资源有限的情况下,将患者分配到怎样的位置,才能降低总体等待时间,合理服务各类患者,排队策略是解决以上问题的关键。

国内外对预约排队策略均有研究,卢林发等^[4]将患者分为普通患者和预约患者,预约患者直接享有插队式服务,但是此方法只适合预约患者远少于普通患者的情况。刘鹏^[5]对患者优先级、等待时间等因素加权求和,根据权重决定就诊顺序。权重按经验给出,并且只分了两个优先级,不能很好地描述现实情况。Wang等^[6]结合患者类型和数量特点,动态调整每天的预约患者和当日来诊患者占有的资源比例。He等^[7]研究了患者优先级提升的问题,给出了相邻优先级跨越所需的等待时间。Jiang^[8]综合考虑患者的等待时间和优先级,利用网格法确定排队策略中的参数,但排队策略还有待进一步优化。

产生能反映真实情况的数据是排队系统仿真的关键一步。大多数研究遵循经典排队理论,将到达过程视为泊松分布,到达率为一个常值^[9-11]。Bockstal等^[12]进一步对泊松达到的两类病人分别给出了不同的到达率。周杰等^[13]为CT室的常规患者建立了Gemo/NB/1排队模型。章顺悦等^[14]为眼科患者建立了G/Ek/c排队模型。由此可见,到达过程并不能用统一的分布去描述。神经网络在学习与预测方面具有优势^[15,16]。相比于其它神经网络,LSTM神经网络能够循环传递神经细胞的时域关联信息,更适合处理时间序列^[17,18]。

借鉴上述研究成果,针对现有策略缺乏系统的优化、数据泛化能力不足的问题,本文建立了LSTM-GA的混合模型:以医疗大数据和深度学习技术为背景,首先,提出用LSTM神经网络学习历史规律,提高模型的对实际问题的描述能力。其次,利用智能优化算法对排队策略进行更深更广的优化。结合模拟退火算法和自适应交叉概率改进传统遗传算法,使全局搜索能力更强^[19]。最后,将历史结果同优化结果对比,分析优化算法的有效性和策略的敏感性。

1 基于LSTM神经网络的数据预测

LSTM神经网络的循环层在时间上是有关联的,当前时刻的输入包含了以前时刻循环层所记忆

的信息,因此能够学习序列在时间上的关联性^[20]。图1是LSTM神经网络按时间展开的结构图。 n 是时间窗口长度, x 是输入数据, \tilde{y} 是网络的输出, h 和 C 是随时间传递的记忆信息。

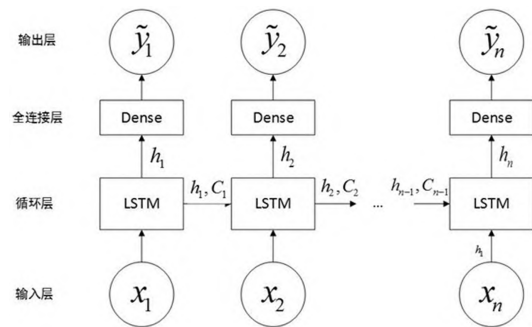


图1 LSTM神经网络结构

神经网络的训练过程如下

1) 参数初始化

对神经元之间的权重系数随机赋予初始值。

2) 前向传播




图2 循环层内部结构

循环层内部结构如图2所示, t 时刻的输出由内部模块的输出、 t 时刻输入以及偏置共同决定,循环层输出 h_t 计算如下

$$h_t = o_t \times \tanh(C_t) \quad (1)$$

$$\text{其中, } C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t \quad (2)$$

$$f_t = \sigma(W_f \times [h_{t-1}, x_t] + b_f) \quad (3)$$

$$i_t = \sigma(W_i \times [h_{t-1}, x_t] + b_i) \quad (4)$$

$$\tilde{C}_t = \tanh(W_c \times [h_{t-1}, x_t] + b_c) \quad (5)$$

$$o_t = \sigma(W_o \times [h_{t-1}, x_t] + b_o) \quad (6)$$

式中, C_t 是输出细胞状态, \tilde{C}_t 是隐藏细胞状态, f_t, i_t, o_t 是激活向量, W_f, W_i, W_c, W_o 是循环层的权重矩阵, b_f, b_i, b_c, b_o 是循环层的偏置项。

循环层输出的信息通过全连接层可以达到特征再提取的目的,最终输出层的输出 \tilde{y} 计算如下:

$$\tilde{y} = \sigma(W_d h + b_d) \quad (7)$$

式中, W_d 是全连接层的权重矩阵, b_d 是全连接层的偏置项。

3) 误差计算, 计算样本输出与期望输出的偏离程度, 误差 L 计算如下

$$L = \frac{1}{2} \sum_{p=1}^N \sum_{k=1}^I (y - \tilde{y})^2 \quad (8)$$

式中 y 为样本的期望输出。

4) 反向传播, 通过梯度下降法迭代更新所有参数, 权重 W_f 的梯度如下所示

$$\frac{\partial L}{\partial W_f} = \sum_{i=1}^n \frac{\partial L}{\partial C_i} \frac{\partial C_i}{\partial f_i} \frac{\partial f_i}{\partial W_f} \quad (9)$$

其余变量的梯度以此类推。

2 基于改进 GA 的排队策略优化

2.1 排队策略及目标函数设计

患者经医护人员预诊断, 根据自身的病情轻重被分为不同优先级, 病情越严重优先级越高, 所期望的等待时间也越短。表 1 给出了某医院为患者划分的优先级和期望等待天数, 优先级为 1 的患者级别最高, 表示病情最严重, 期望等待天数最短。

表 1 患者优先级与预期等待天数

患者优先级	预期等待时间/天
1	1
2	2
3	10
4	28

排队策略给每位患者赋予不同权重, 按照权重大小给患者分配就诊顺序, 权重越大, 越优先占用医疗资源。若出现权重相同的情况, 则预约申请时间更早的患者在前。权重 w 与优先级和等待天数相关, 计算如下

$$w = a \times P_i + b(t - Target_i), (i = 1, 2, 3, 4) \quad (10)$$

其中, a 和 b 是决策变量, 决定了优先级和等待时间对权重的影响程度; P_i 是优先级 i 的初始系数; t 是患者的等待天数, $Target_i$ 是优先级的期望等待天数, 对应关系如表 1。 a 、 b 、 P_1 、 P_2 、 P_3 和 P_4 为待优化参数, 共同决定了患者-资源的分配原则。

将目标函数 E 设定为平均超出时间, 对不同优先级患者的超出等待时间做加权处理。目标函数 E 如下

$$E = \frac{1}{N} \sum_{d=1}^T d \times k_i \times n_d \quad (11)$$

其中, N 是仿真期间到达的患者总数; T 是仿真天数; d 是超出等待时间, 即患者的等待时间减去其优先级对应的期望等待时间; k_i 是优先级的超出等待时间加权系数, 分别取 4, 3, 2, 1; 是超出等待时间为 d 天的患者人数。

本文结合该科室实际情况做出以下合理假设:

- 1) 患者预约后会在队列中等待直到就诊。
- 2) 患者的就诊时长与优先级无关。
- 3) 患者一次的就诊时长不超过一天。

2.2 改进 GA 优化流程

遗传算法对优化问题没有太多的数学上的限制, 对于多种形式的目标函数和约束, 比如线性或者非线性, 离散或者连续都可处理。由于算子具备各态历经性, 因此算法能进行概率层面的全局搜索。

改进 GA 算法具体步骤如下

1) 初始化

设置交叉概率、变异概率、种群的个体数目和最大迭代次数, 给种群的染色体随机赋值。

2) 编码与解码

采用二进制编码, 解的精度为 $delta$ 。对于第 i 个变量 x , 给出解的上边界 X_{i+} 和下边界 X_{i-} , 第 i 个变量的编码长度 L_i 的计算如下

$$L_i = \lceil \log_2 \left(\frac{X_{i+} - X_{i-}}{delta} + 1 \right) \rceil \quad (12)$$

若第 n 个变量的染色体长度为 n , 其二进制编码 $X_i = b_{n-1}b_{n-2}, \dots, b_0$, 要将二进制的编码解析为数解, 解码的计算方法如下

$$X_i = X_{i-1} + delta \sum_{m=0}^{n-1} (2^m \times b_m) \quad (13)$$

3) 计算个体适应度

本文期望目标函数取得最小值, 为满足当目标函数值减小时适应度值增大的要求, 设计适应度函数与目标函数成反比。

4) 选择

个体被选中的概率如下

$$P_i = f(indv_i) / \sum_{j=1}^M f(indv_j) \quad (14)$$

其中 P_i 是第 i 个个体被选中的概率, $indv_i$ 是第 i 个个体对应的解, M 是种群的规模。

5) 自适应交叉

简单遗传算法中交叉概率为常数, 这使得算法的收敛能力和寻优能力不能相互协调。自适应交叉概率旨在实现搜索和收敛的平衡^[21]。当种群多样性变高时, 种群中最大适应度和平均适应度之间的差是增大的, 交叉概率应当减小。交叉概率的计算如下

$$P_c = \begin{cases} \frac{k_1 F_{\max} - F'}{F_{\max} - F_{\text{avg}}} & F' > F_{\text{avg}} \\ k_2 & F' \leq F_{\text{avg}} \end{cases} \quad (15)$$

其中, F_{\max} 和 F_{avg} 是最大适应度和平均适应度,

k_1 和 k_2 是 0 到 1 之间的常数, F' 是两个交叉个体中较大的适应度值。

6) 模拟退火变异

模拟退火变异方法旨在跳出局部最优, 寻找全局最优解^[22], 以一定概率接受差的变异, 概率按照 Metropolis 准则^[23] 计算如下

$$\begin{cases} P_m = e^{\Delta E/T_{iter}} \\ T_{iter} = 0.95^{iter-1} T_0 \end{cases} \quad (16)$$

ΔE 是能量的改变, 应用于遗传算法即是变异前后目标函数的差值, T_{iter} 是系统的温度, $iter$ 是当前种群的迭代次数, T_0 是系统的初始温度。

7) 重复上述步骤 2) ~ 6), 直到迭代次数达到最大。

3 LSTM-GA 混合模型优化系统

将 LSTM 神经网络与改进 GA 相结合, 对策略进行优化, LSTM-GA 混合模型结构如图 3 所示, 其过程如下:

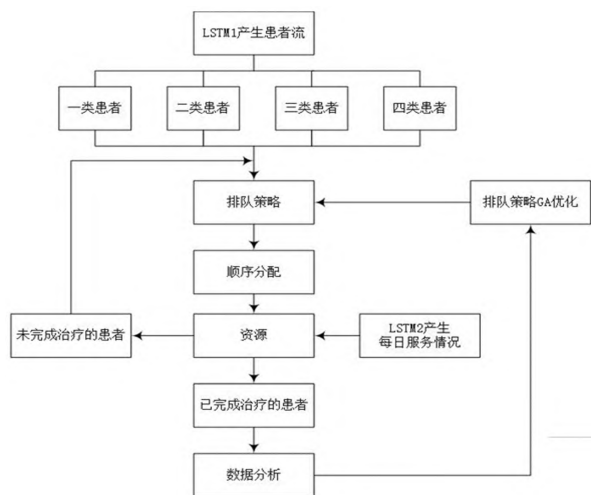


图3 LSTM-GA 混合模型结构

Step 1 LSTM 神经网络通过对历史数据的学习, 产生四类患者的每日到达数量。四类患者分别为濒危、危重、急症和非急症。

Step 2 根据排队策略分配患者占有资源的先后顺序, 权重大的患者排在队列前。

Step 3 LSTM 神经网络产生每日服务患者的数量。完成治疗的患者离开队列, 未完成治疗的患者更新自身属性。

Step 4 在仿真时长内不断重复 Step1 ~ Step3。

Step 5 策略优化模块统计患者的优先级、等待情况等属性, 计算出目标函数值。利用改进 GA 算法不断迭代优化决策变量, 降低患者等待时间。

本文待优化的参数是 a 、 b 、 P_1 、 P_2 、 P_3 和 P_4 , 利用分层优化的思想将 a 、 b 定义为外部参数, $P_1 \sim P_4$ 定义为内部参数。先对内部参数进行优化, 然后基于此组内部参数再对外部参数进行优化。

4 案例计算与分析

4.1 数据预处理

为验证本文方法的有效性, 获取了国外某医院某科室近五年患者预约检查的医疗数据, 共包含 55354 条患者就诊信息, 每条信息描述了病人申请治疗日期、优先级、期望等待天数和实际治疗日期等。

4.2 数据预测与对比分析

建立 LSTM 神经网络模型预测一年的患者每日到达量和每日服务量。为了验证本文 LSTM 神经网络预测的效果, 本文建立经典排队理论的随机型输入过程与之对比。

结合经验公式以及反复试验^[24], 设计网络拓扑结构为 $7 \times 16 \times 32 \times 1$, 分别为输入层、循环层、全连接层和输出层。为避免网络出现过拟合, 一方面采用 Hinton 等^[25] 提出的 Dropout 技术, Dropout 率为 0.2, 随机切断 20% 的神经元之间的连接; 另一方面在循环层增加正则化方法, 惩罚项系数 0.001, 应用于循环层的非偏置项。

假设每日患者到达量和服务量服从表 2 所列分布, 对其进行非参数检验。服务阶段的泊松分布的渐进显著性略微高于 0.05, 其余分布的渐进显著性都低于 0.05, 说明了实际数据的特征不适用上述经典分布描述。

表2 每日患者到达量与服务量分布检验

	假设分布	均值	标准差	最大值	最小值	K-S 统计量	渐进显著性(双侧)
到达阶段	泊松分布	42.17	-	-	-	1.549	0.017
	正态分布	42.17	26.86	-	-	0.202	0.003
	均匀分布	-	-	2	79	1.243	0.095
服务阶段	泊松分布	40.03	-	-	-	1.332	0.057
	正态分布	40.03	9.771	-	-	0.206	0.002
	均匀分布	-	-	21	55	1.609	0.011

选择效果相对好的泊松分布和均匀分布与神经网络进行对比。以历史数据作为参考,对每日的患者到达数量进行预测,如图4所示,泊松到达太过平稳,未能体现真实的到达情况,均匀分布的到达过程波动剧烈,远远超出了真实状态,LSTM神经网络预测的到达过程很好地跟随了真实数据的规律。相应

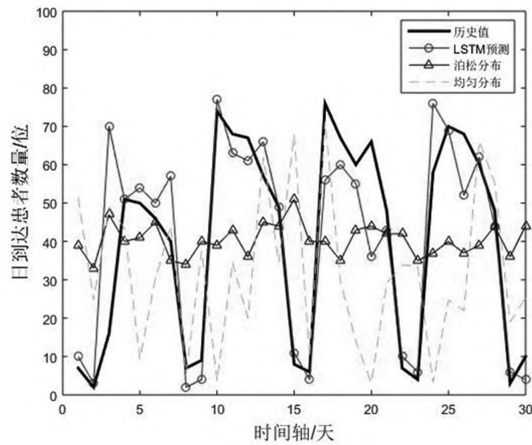


图4 达到情况对比

表3 各模型结果评价指标

模型		评价指标		
		RMSE	MAE	MAPE
到达过程	LSTM 神经网络	13.55	7.93	10.79
	负指数分布	26.16	23.23	18.38
	几何分布	33.26	26.13	78.88
服务过程	LSTM 神经网络	7.43	5.48	3.96
	负指数分布	12.26	10.34	8.09
	负二项分布	27.44	24.25	55.90

利用 LSTM 神经网络预测每日到达的患者数量,根据历史数据统计各优先级患者的百分比,将预测得到的每日到达患者乘以各优先级百分比,得到每天各个优先级患者的到达数量。由于假设患者的治疗时长与优先级无关,所以每日服务的患者数量与优先级无关,直接以神经网络输出为当日服务数量。

将 LSTM 神经网络预测的数据输入混合模型,利用改进遗传算法对策略参数分层优化,算法的参数设计如表4所示, P_c 是交叉概率, P_m 是变异概率, T_0 是初始温度, Acc 是编码精度, Len 是染色体长度, M 是个体数目, $MaxIter$ 是最大迭代次数。

表4 优化算法参数设置

参数	P_c	P_m	T_0	Acc	Len	M	$MaxIter$
改进 GA	$k_1 = 0.5$	0.4	8	0.01	23	10	100
	$k_2 = 0.8$						
传统 GA	0.8	0.4	-	0.01	23	10	100

地对每日服务患者的数量进行对比,如图5所示,同样 LSTM 神经网络对趋势有更准确的预测能力。

采用表3评价指标评价预测能力,神经网络在各项指标上都明显高于随机分布的结果,说明了 LSTM 神经网络产生的到达过程和服务过程能更好地反映真实情况。




图5 服务情况对比

4.3 GA 优化与对比分析

先优化内部参数,传统 GA 和改进 GA 优化内部参数的过程如图6所示。传统 GA 和改进 GA 分别将目标函数降到了 15.58 天和 14.01 天。将第一次优化得到的参数保存,再加入外部参数并对其优化。传统 GA 和改进 GA 优化外部参数过程如图7所示。在前次优化的基础上,目标函数值再次下降,最终分别为 11.24 天和 8.06 天。由此可见,二次优化可以再次降低目标函数,改进 GA 的寻优能力仍然强于传统 GA,得到了更优的解,最终优化参数如表5所示。




图6 内部参数优化过程

表5 最终优化参数

参数	P_1	P_2	P_3	P_4	a	b
值	17.0995	18.9483	16.6258	0.27649	6.9663	2.1839




图7 外部参数优化过程

利用改进 GA 对多个年份进行优化,每个年份都分别仿真 50 次,将优化后目标函数的平均值与优化前的做对比,得到的结果如表 6 所示。可以看出优化后的策略给排队系统带来了可观的积极影响,优化后目标函数平均值明显低于优化前的目标函数值,表明了改进 GA 优化排队策略能够降低患者等待时长。标准差明显低于平均值,体现了优化算法的表现能力比较稳定。

表 6 历年排队策略优化结果

年份	优化前目标函数值	优化后目标函数平均值	优化后目标函数标准差	平均下降百分比(%)
2014	19.93	8.06	3.75	59.5
2015	29.67	15.30	5.53	48.4
2016	35.83	26.97	9.74	24.7
2017	24.81	16.14	5.82	34.9

4.4 策略敏感性分析

将先来先服务策略、严格优先级策略与本文得到最优累计加权策略对比。三种策略下各优先级超出目标等待天数的百分比如下所示。先来先服务策略是超出百分比指标在各个优先级都表现不佳,严重阻碍了患者的就诊。严格优先级虽然给予了前三个优先级患者充分的就诊机会,但第四优先级患者的就诊受到了明显的限制,超过 90% 的第四优先级患者未能在其目标等待时间内就诊,从数量上分析损害了很大一部分患者的治疗。本文的累计加权策略给绝大部分病情严重的第一第二优先级患者及时治疗,对于第三优先级患者,超出

百分比略高于严格优先级策略,但第四优先级患者的超出百分比有明显的降低,其分布更较前两种策略加合理。考虑平均超出等待时间,三种策略下该指标分别为 11.73 天、9.88 天、8.06 天,本文策略在超出百分比和平均超出等待时间上都取得了良好的效果。




图8 三种策略下超出目标等待时间的比例




图9 策略敏感性分析

为验证排队策略是否在各个时段都发挥作用,对策略进行敏感性分析。将 300 天的时间跨度平均分割为三个时段,每个时段都采用表 5 对应的排队策略,仿真得到三个时段优化后的目标函数值,与历史数据下的目标函数值对比。每年还余下 65 天或 66 天的数据未参与优化,再将策略应用于未参与优化的时段,对比分析策略发挥的效果。2014 年的敏感性分析结果如图 9 所示,其余年份各时段的敏感性分析如表 7 所示。

表 7 各时段目标函数值

	年份	第 1 ~ 100 天	第 101 ~ 200 天	第 201 ~ 300 天	余下
优化值	2015	22.72	26.75	14.40	22.20
	2016	25.28	33.39	23.31	28.21
	2017	22.80	23.03	11.82	18.46
	2015	26.27	30.38	30.27	32.62
历史值	2016	30.60	41.26	35.63	35.96
	2017	28.67	28.34	20.36	20.47

从图9和表7可以看出,在各年各时段中,应用了排队策略的目标函数值都明显低于该时段的历史值,这表明排队策略在仿真各时段内均发挥了效能。因此本文优化的排队策略具有一定的稳定性和时间普适性。

5 结论

本文建立了 LSTM-GA 混合模型,对预约患者的排队策略进行了优化研究。在数据上,提出用 LSTM 神经网络预测到达过程和服务过程,提高了数据的泛化能力,增强了策略对未来的指导意义。在排队策略优化上,扩充了可优化参数集,从更广的范围对策略进行了优化;利用改进 GA 提高了全局搜索能力和收敛能力。本文获得的排队策略从总体上显著降低了患者的等待时长,策略在不同时段均能发挥明显效能,对时间因素具有一定的抗干扰能力。

本文的研究方法和成果对患者预约排队问题有一定的实际意义。虽然我国目前只在部分医院开展分级就诊和预约就诊,但随着探索的深入,这会成为将来就诊的重要手段。本文的研究为合理规划预约排队问题提供了一种有效的方法。同时本文也有待完善,未来可以研究多家医院之间医疗资源与患者相互分配的问题。

参考文献:

- [1] 余幸. 大医院“检查排队”考验“分级诊疗”制度[N]. 经济日报, 2019-03-29(012).
- [2] Chakraborty S, Muthuraman K, Lawley M. Sequential clinical scheduling with patient no-shows and general service time distributions [J]. IIE Transactions, 2010, 42(5): 354-366.
- [3] 郑宇飞. 让急诊姓“急”不能止于分级[N]. 北京日报, 2019-04-26(007).
- [4] 卢林发, 牛瑛. 一种优化的预约排队算法分析及实现[J]. 现代医院, 2009, 9(11): 92-96.
- [5] 刘鹏. 改进加权补偿优先双轮询调度算法在医院预约分诊排队管理中的应用[J]. 中国数字医学, 2017, 12(3): 70-72.
- [6] Wang G L. Revenue management for a primary-care clinic in the presence of patient choice[J]. Operations Research, 2008, 56(3): 576-592.
- [7] He Q M, Xie J, Zhao X. Priority queue with customer upgrades[J]. Naval Research Logistics, 2012, 59(5): 362-375.
- [8] Jiang Y. Data-driven analytics to support scheduling of multi-priority multi-class patients with wait targets[D]. Waterloo University, 2016.
- [9] Kopach R, Delaurentis P C, Lawley M, et al. Effects of clinical characteristics on successful open access scheduling[J]. Health Care Management Science, 2007, 10(2): 111-124.
- [10] Crowther M J, Riley R D, Staessen J A, et al. Individual patient data meta-analysis of survival data using poisson regression models[J]. BMC Medical Research Methodology, 2012, 12(1): 34.
- [11] 任宗伟, 郭海妮. 考虑患者回诊情况下的门诊科室调度优化[J]. 运筹与管理, 2018, 27(04): 39-49.
- [12] Bockstal E V, Maenhout B. A study on the impact of prioritising emergency department arrivals on the patient waiting time[J]. Health Care Management Science, 2018: 1-26.
- [13] 周杰, 李军, 郭鹏, 余妙妙. 急诊非强占优先权下Geom/NB/1 排队系统常规病人等待时间及损失率[J]. 系统工程理论与实践, 2016, 36(8): 2135-2143.
- [14] 章顺悦, 杨扬, 吴家利, 等. 排队论 G/Ek/c 模型及其在医院眼科专家门诊中的应用[J]. 中国卫生统计, 2012, 29(4): 484-486, 489.
- [15] Lv Y, Duan Y, Kang W, et al. Traffic flow prediction with big data: a deep learning approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(2): 865-873.
- [16] Chen H, Canizares C A, Singh A. ANN-based short-term load forecasting in electricity markets[C]. Power Engineering Society Winter Meeting. IEEE, 2001. 411-415.
- [17] Shi H, Xu M H, Li R. Deep learning for household load forecasting-a novel pooling deep RNN[J]. IEEE Transactions on Smart Grid, 2018, 9(5): 5271-5280.
- [18] Yin Z, Zhu J, Zhang X. Forecast customer flow using long short-term memory networks[C]. 2017 International Conference on Security, Pattern Analysis, and Cybernetics (SPAC). IEEE, 2018. 61-66.
- [19] Chen Y, Li X, Miao M, et al. Multi-objective and hierarchical optimization of power collection system for photovoltaic power plants based on the multi-elite co-evolutionary partheno-genetic algorithm [J]. Power System Protection & Control, 2016, 44(12): 29-35.
- [20] Yang Y, Dong J, Sun X, et al. A CFCC-LSTM model for sea surface temperature prediction [J]. IEEE Geoscience and Remote Sensing Letters, 2017, 15(2): 1-5.
- [21] 陆坚毅, 杨超, 揭婉晨. 考虑绕行特征的电动汽车快速充电站选址问题及自适应遗传算法[J]. 运筹与管理, 2017, 26(01): 8-17.
- [22] Liao G C, Tsao T P. Application of a fuzzy neural network combined with a chaos genetic algorithm and simulated annealing to short-term load forecasting[J]. IEEE Transactions on Evolutionary Computation, 2006, 10(3): 330-340.
- [23] Zhao X C. Simulated annealing algorithm with adaptive neighborhood[J]. Applied Soft Computing, 2011, 11(2): 1827-1836.
- [24] 张凌波, 宰娜, 顾幸生. 基于改进教学算法优化 BP 神经网络的催化剂碳含量预测模型[J]. 控制与决策, 2016, 31(9): 1723-1728.
- [25] Mohamed A, Dahl G E, Hinton G. Acoustic modeling using deep belief networks[J]. IEEE Transactions on Audio, Speech and Language Processing, 2012, 20(1): 14-22.